Calculateur CO_2 logistique intelligent







Projet Data Wrangling · FastColis

Kheireddine BOUADI, Maël RAZAFIMBELO, Mohamed BEN AMOR, Ael Boece NGODA LONTSI, Abdallah BENSMAIL

PGE3 · aivancity · octobre 2026

L'avion pèse 84 % des émissions pour 12 % des colis

84 %

des émissions viennent des colis qui prennent l'avion

12 %

des colis seulement, presque tous venus d'Asie

60 000

colis analysés sur 12 mois

49,7 t

de CO_2e au total

89 g

pour le colis médian

± 2,2 %

d'erreur médiane face à la réalité

Un CO_2 par colis, même sur une chaîne incomplète

Objectifs métier

Comparabilité
une méthode unique (EN 16258, facteurs ADEME) pour tous les clients

Transparence
chaque gramme se rattache à une étape, un véhicule, une source

Anticipation
estimer un envoi avant expédition pour orienter le choix du service

Contraintes

Sources hétérogènes
SAP, logs de scanners en deux formats, Excel transporteurs

Chaîne incomplète
scans oubliés, transporteurs non renseignés, colis en transit

Aucun référentiel
ni distances, ni facteurs, ni topologie du réseau prêts à l'emploi

Neuf sources, dont cinq référentiels publics réels

Source	Format	Apport	Nature
Export SAP	CSV Windows-1252, « ; », virgule décimale	commandes, poids, dimensions, service	simulée
Flashages	12 fichiers JSON Lines, 2 firmwares	362 199 scans : site, heure, GPS, transporteur	simulée
Annuaire transporteurs	Excel, 2 onglets différents	véhicule et énergie de 110 flottes	simulée
Référentiel des sites	CSV	129 plateformes, agences, entrepôts	simulée
Base Carbone ADEME	CSV latin-1, 18 616 lignes	22 facteurs fret, identifiants officiels	**réelle**
GeoNames	TSV, 69 000 villes	géocodage, population, fuseaux	**réelle**
OpenFlights	CSV	aéroports partenaires (IATA)	**réelle**
OSRM (OpenStreetMap)	API	16 512 distances routières réelles	**réelle**
searoute	bibliothèque Python	routes maritimes (Suez compris)	**réelle**

Les sources internes sont simulées avec des défauts réalistes et une vérité terrain cachée : on peut mesurer la qualité du pipeline, ce qu'aucune donnée réelle ne permet.

Sept étapes, relancées de bout en bout en 90 secondes



rapport de profilage par formes	couche brute Parquet tracée	Raw Clean + journal des règles	géocodage, trajets, distances	véhicules, facteurs, 3 modèles	13 règles + vérité terrain	Curated, Excel clients, interface

`python run_pipeline.py` un module Python par étape (paquet co2), 17 tests unitaires, notebook exécuté, journal de chaque transformation

Chaque défaut est trouvé, corrigé et journalisé

3 formats de date
20260314, 14.03.2026, 2026-03-14

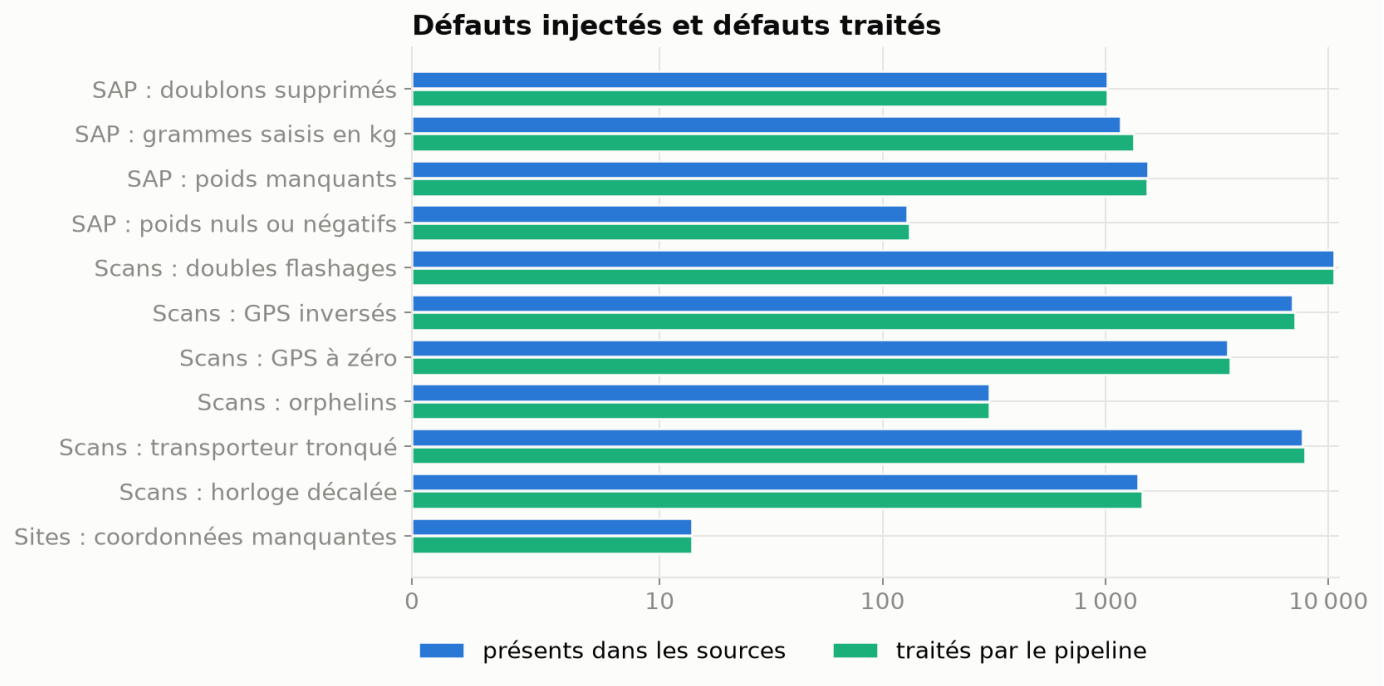
22 libellés pour 8 clients
AMAZON EU SARL, amazon.fr…

1 334 poids en grammes
déclarés en kg, divisés par 1 000

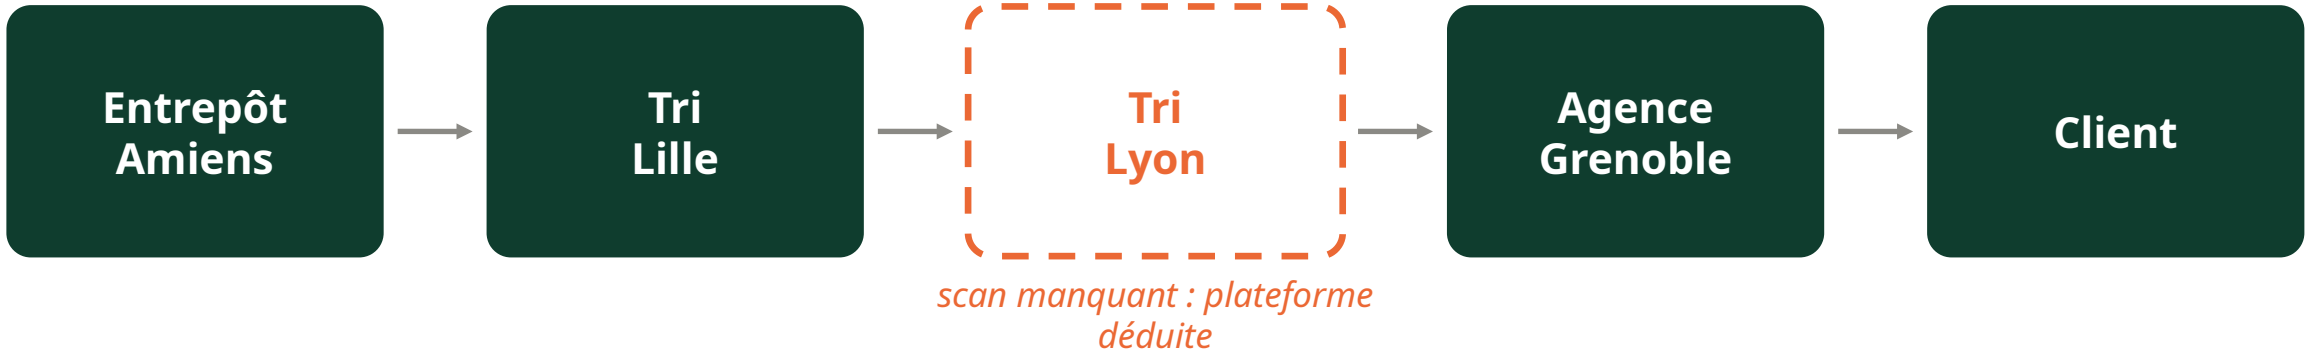
2 firmwares de scanner
epoch en ms et codes courts contre ISO 8601

7 048 GPS inversés
détectés par distance au site

10 539 doubles flashages
même scan à moins de 5 minutes



Les scans manquants sont déduits du réseau



117

rattachements agence ou entrepôt → plateforme appris dans les scans (vote majoritaire)

15,8 %

des colis ont au moins une étape déduite, sans perte de précision notable

98,5 %

de bonnes prédictions du mode (avion, bateau, route) quand la porte d'entrée n'est pas flashée, contre 87,4 % pour la règle par pays

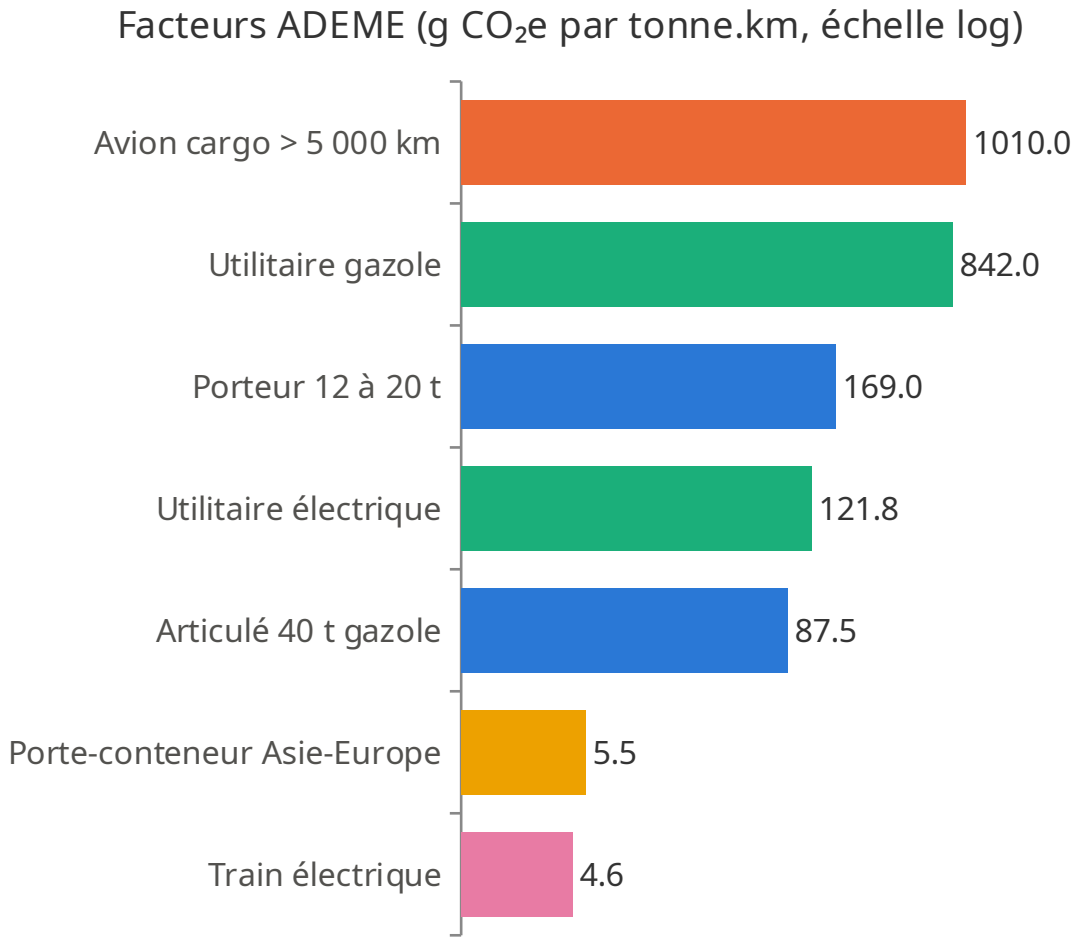
Distances réelles par mode, facteurs officiels de l'ADEME

Route
distance OSRM réelle entre sites ; sinon vol d'oiseau × 1,27, calibré sur 16 512 trajets

Avion
orthodromie + 95 km (norme EN 16258), facteur selon la distance, traînées incluses

Bateau
route maritime réelle (searoute), facteur de la ligne Asie-Europe

Dernier km
tournée : distance × 1,6 ; −40 % en point relais

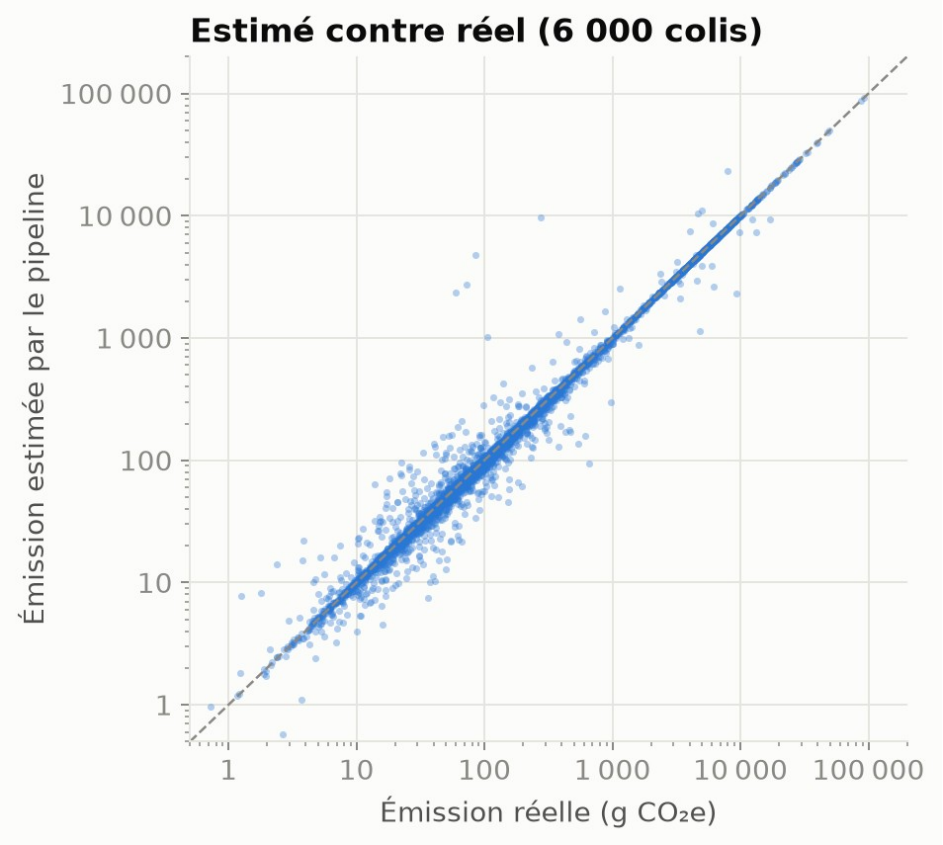


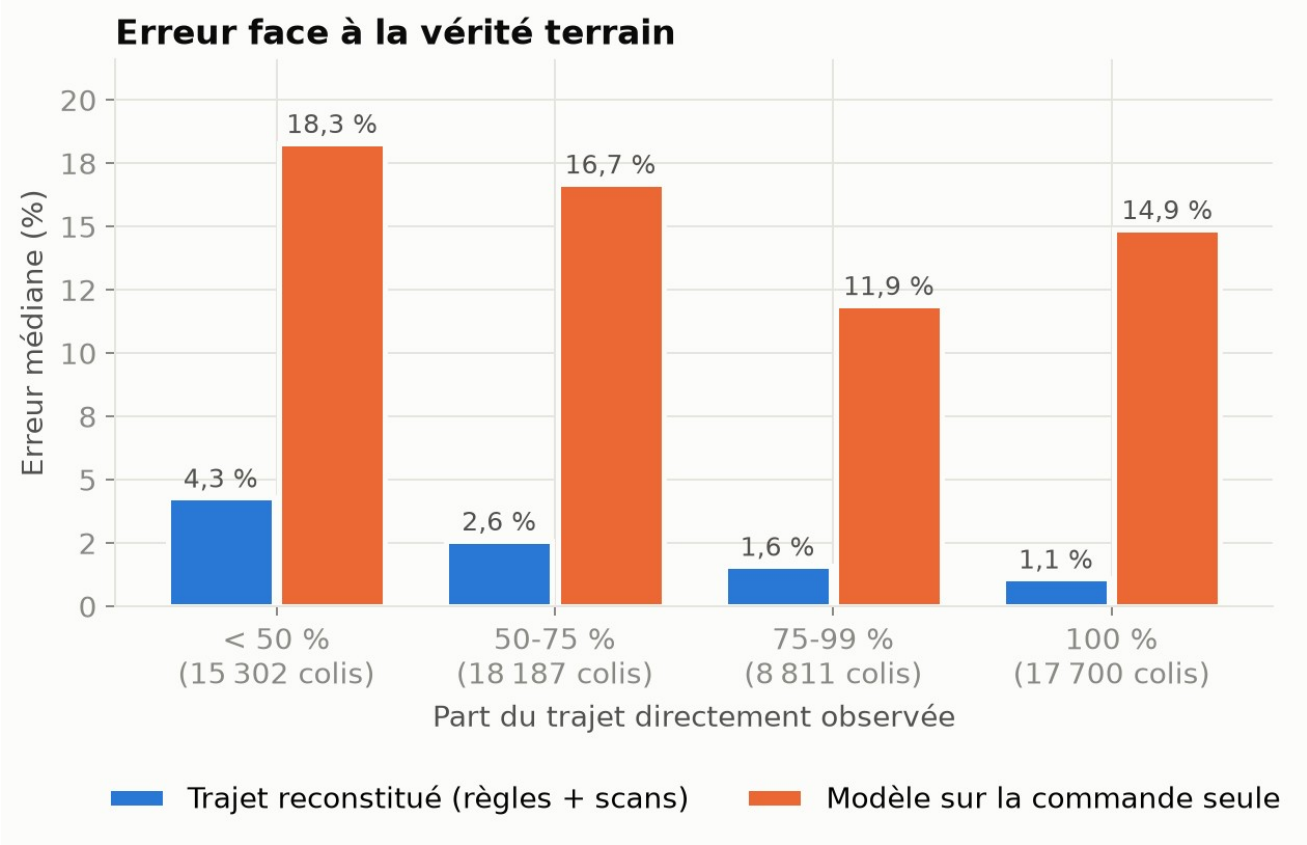
Trois modèles, chacun comparé à une règle simple

Question	Utilisé pour	Règle simple	Modèle
Avion, bateau ou route ?	colis étrangers sans scan d'entrée	87,4 % (mode du pays)	**98,5 % de bonnes réponses**
Quel véhicule ?	étapes sans transporteur (70 % des colis)	69,7 % (le plus fréquent)	**70,7 % + facteur moyen pondéré**
Combien de CO_2 avant l'envoi ?	calculateur, contrôle des anomalies	55,7 % d'erreur médiane	**16,8 %, intervalle à 80 % tenu à 79 %**

Ce qu'on en retient
Le véhicule exact est peu prévisible : le modèle gagne un point seulement. Mais en pondérant les facteurs par ses probabilités au lieu de prendre la classe la plus probable, le biais sur le total de l'option écologique passe de −6 % à −0,8 %. Les intervalles sont calibrés par régression quantile conformalisée.

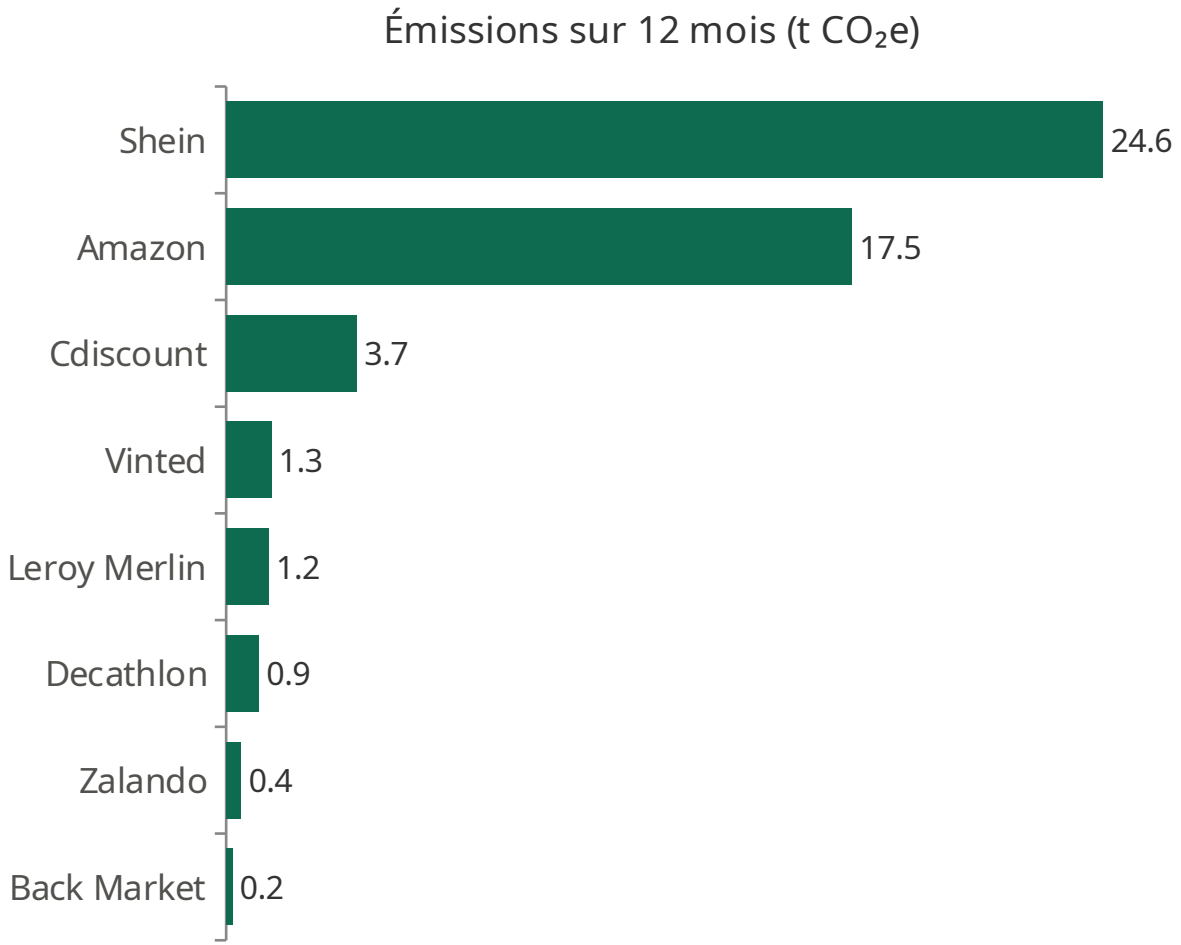
2,2 % d'erreur médiane face à la vérité terrain





Biais sur le total de l'année : 0,50 %. 92,2 % des colis à moins de 20 % près. 13 règles de cohérence : 11 OK, 2 alertes sous 1 %.

Shein et Amazon concentrent 85 % des émissions

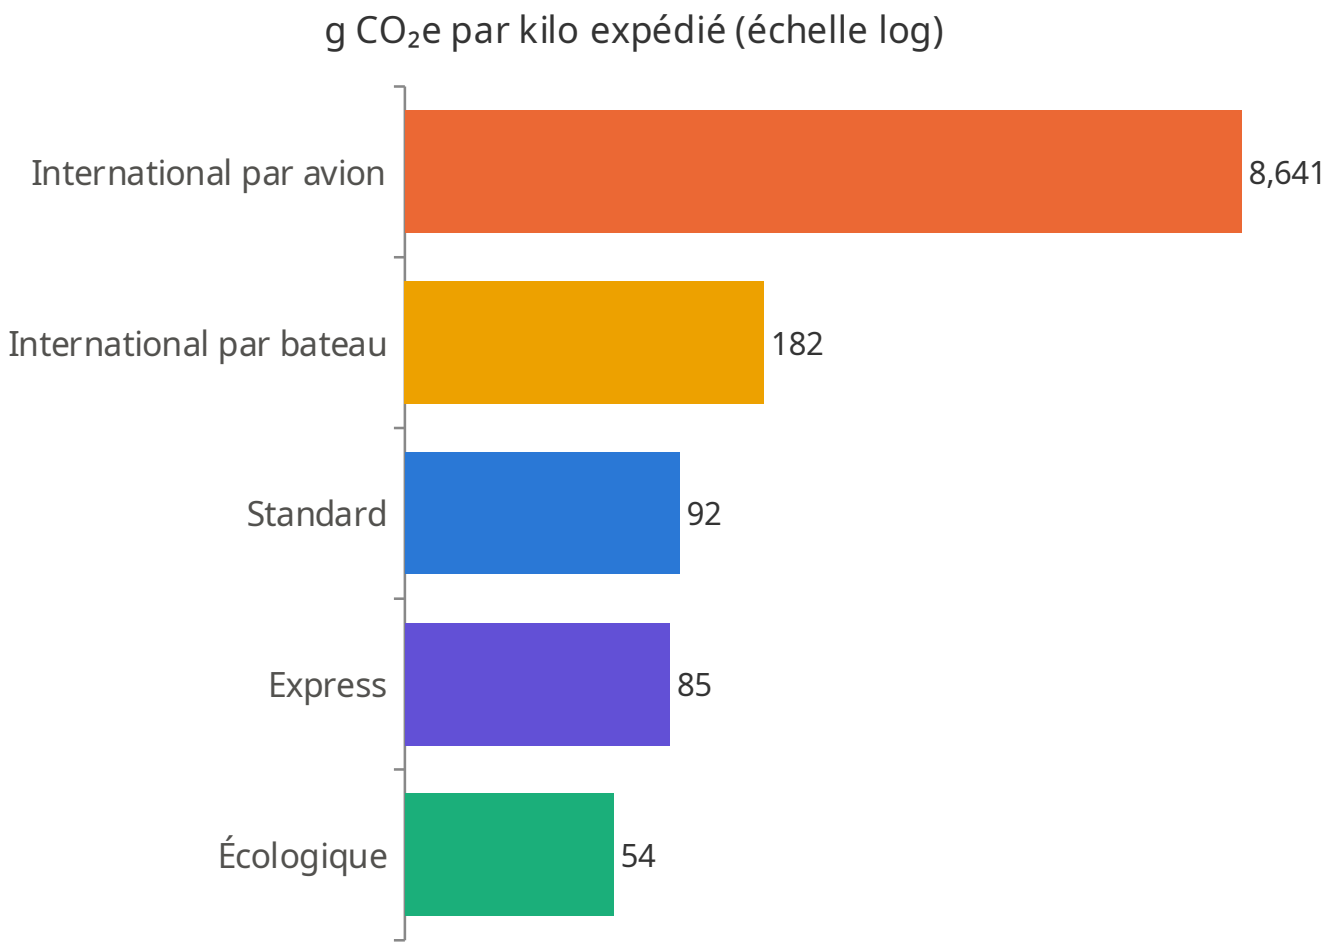


Shein
10 % des colis, 49 % des émissions : 99 % par avion, 4 kg par colis

Amazon
le colis médian émet 75 g, mais environ 8 % d'imports font 87 % du total

Vinted
13 142 colis entre particuliers pour 1,3 t : 96 g par colis, point relais majoritaire

Un kilo d'Asie : 8,6 kg CO_2e en avion, 182 g en bateau

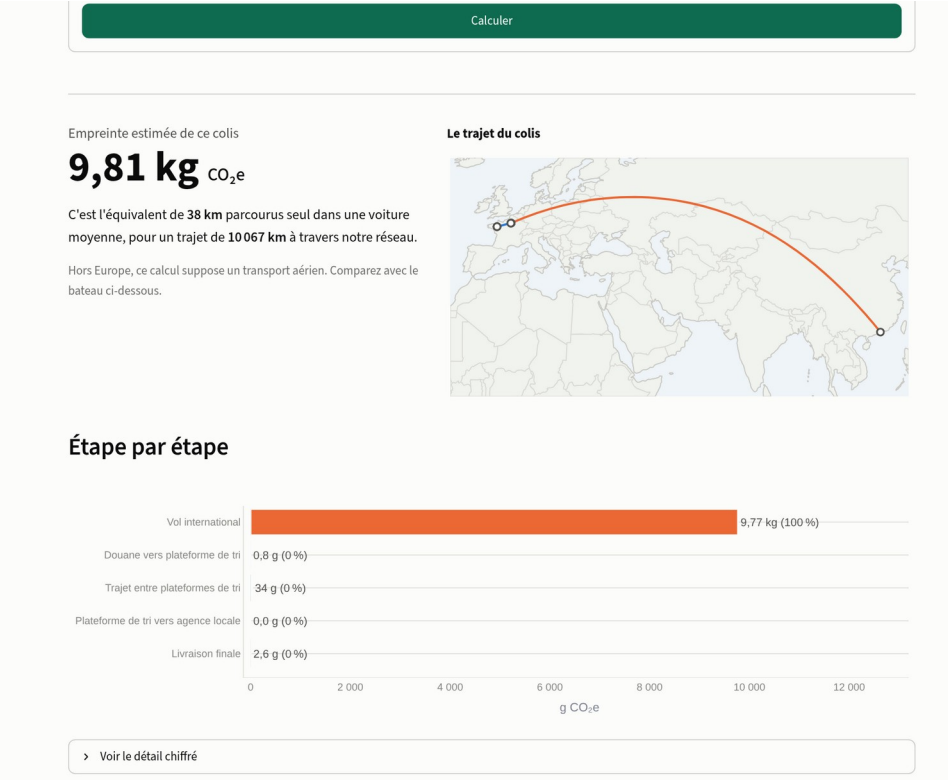


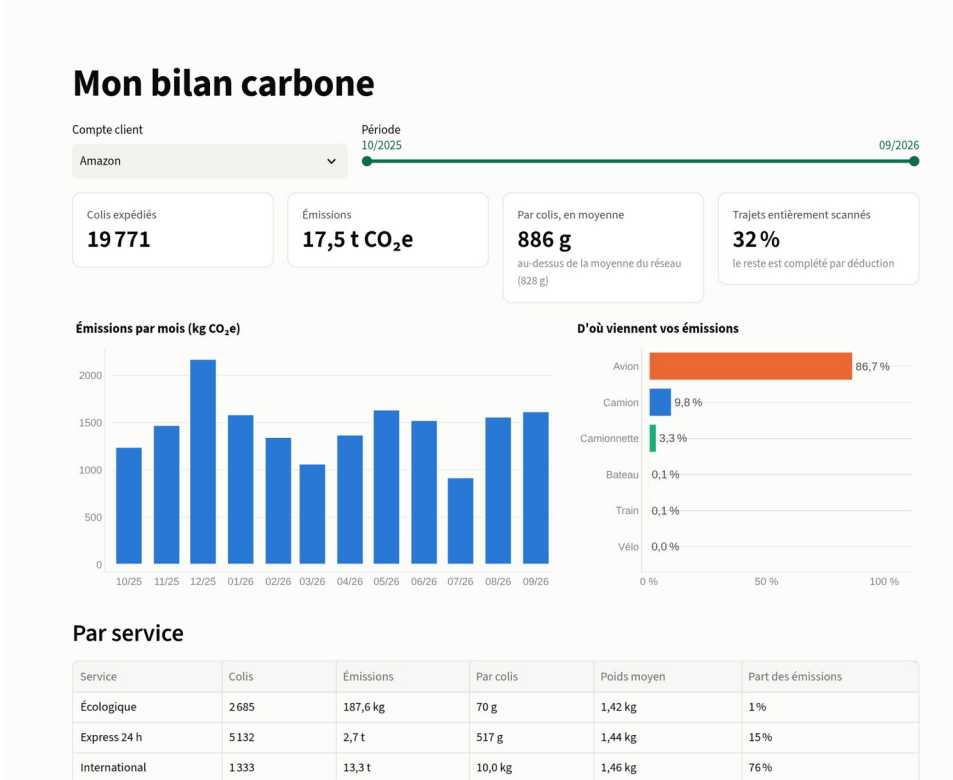
× 47 — l'écart entre avion et bateau pour un même kilo

− 41 % — l'option écologique face au standard (train, électrique, vélo cargo)

≈ 0 — l'écart entre express et standard sur le territoire : l'express roule en ligne directe

Une interface pensée pour un client non technique





Calculer un envoi
départ, arrivée, poids : l'empreinte, le trajet, les autres options

Mon bilan carbone
mois par mois, par mode, leviers simulés, export Excel

Comment c'est calculé
la méthode en clair, les facteurs ADEME et les limites

Organisation Scrum : 4 epics, 3 sprints de deux semaines

Epic	Exemple de user story	Sprint
1. Ingestion des sources	En tant que data engineer, je veux charger SAP, scans et transporteurs dans un format unique	1
2. Qualité et nettoyage	En tant que data steward, je veux un journal de chaque correction appliquée	1
3. Calcul et modèles	En tant que data scientist, je veux estimer le véhicule quand le transporteur manque	2
4. Restitution client	En tant que responsable RSE d'un client, je veux mon bilan CO_2 mensuel en Excel	3

Definition of Done : code testé, étape journalisée, règle de validation verte, documentation à jour.

L'équipe

Kheireddine BOUADI
Product Owner, data engineer

Maël RAZAFIMBELO
Scrum Master, validation

Mohamed BEN AMOR
Data engineer, nettoyage

Ael Boece NGODA LONTSI
Data scientist, modèles

Abdallah BENSMAIL
Data analyst, interface

Limites et prochaines étapes

- Brancher les vraies extractions SAP et scanners : le pipeline ne dépend que du format
- Ajouter les émissions des plateformes et le trajet du client vers le point relais
- Remplacer le coefficient de tournée par les vraies tournées (GPS des véhicules)
- Exposer le calculateur en API pour l'afficher au moment de la commande